

MAPEAMENTO DE DISTÚRBIOS FLORESTAIS NO ESTADO DO MARANHÃO POR MEIO DE SÉRIES TEMPORAIS E CUBOS DE DADOS

Wesley Augusto Campanharo¹, Celso H. L. Silva-Junior^{2,3}, Mateus de Souza Macul¹, Karine R. Ferreira¹ e Gilberto Ribeiro de Queiroz¹

¹ Divisão de Observação da Terra e Geoinformática (DIOTG), Instituto Nacional de Pesquisas Espaciais (INPE), Av. dos Astronautas, 1758, São José dos Campos, SP, Brazil. (wesley.campanharo, mateus.macul, karine.ferreira, gilberto.queiroz)@inpe.br.

² NASA Jet Propulsion Laboratory (JPL), Pasadena, California, US

³ University of California Los Angeles (UCLA), Los Angeles, California, US. celsohlsj@ucla.edu

RESUMO

A utilização de séries temporais na detecção de distúrbios florestais mais complexos vem ganhando relevância nos últimos anos. O algoritmo BFAST é um dos modelos desenvolvidos para capturar essas alterações, indicando mudanças e tendências. Assim, pretendeu-se identificar áreas florestais com distúrbios em 2020 considerando o seu comportamento entre 2016 e 2019. Para tanto, utilizou-se séries temporais de NDVI derivados de imagens do Landsat disponibilizado pelo BDC, e do algoritmo BFAST_monitor, utilizando o estado do Maranhão como área de estudo. Do total monitorado (127.072 km²) foram identificadas 36.521 km² com algum tipo de distúrbio, deste total cerca de 15% são em áreas vulneráveis (com declínio na tendência), 35% em áreas sem tendência e 50% em áreas em crescimento. A área mapeada com distúrbio é considerada pequena, pois o modelo apresentou baixa acurácia do usuário para a determinação de distúrbios, evidenciando que muito dos distúrbios não foram corretamente classificados.

Palavras-chave – BFAST, séries temporais, Incêndios, Desmatamento, Degradação.

ABSTRACT

The use of time series in the detection of more complex forest disturbances has gained relevance recently. The BFAST is one of the models developed to capture these changes, indicating breaks and trends. Thus, we aim to identify disturbances in forest areas during 2020, considering their behavior between 2016 and 2019. For this, we use NDVI time series derived from Landsat imagery provided by the BDC, and the BFAST_monitor algorithm, using the state of Maranhão as a study area. Of the total monitored (127,072 km²), 36,521 km² were identified with some type of disturbance, of this total about 15% are in vulnerable areas (with a decline in trend), 35% in areas without trend and 50% in areas with growth. The area mapped with disturbance is considered small, once the model presented low user accuracy for the determination of disturbances, showing that many of the disturbances were not correctly classified.

Key words – BFAST, time-series, Fires, Deforestation, Degradation.

1. INTRODUÇÃO

Em ecossistemas florestais um distúrbio pode ser definido como "eventos de exploração pontual no espaço, resultante de impactos de intensidade moderada e que não impede a recuperação florestal ao longo de um espaço de tempo". [1, p.19], ou ainda como "um evento relativamente discreto que causa uma mudança na estrutura física do ambiente" [2, p.293]. Ambos trazem o caráter pontual e a consequente alteração no ambiente floresta causada pelo distúrbio. Entretanto, quanto estes eventos ultrapassam certos limites espaciais e ecológicos, promovendo a redução da capacidade de fornecer bens e serviços, a deterioração dos estoques de carbono, a redução da biodiversidade, a deterioração do ciclo da água ou a redução na proteção do solo, estes fenômenos podem, então, serem classificados como degradação florestal [1].

Nesse sentido as principais fontes de degradação florestal conhecidas são, o desmatamento, o fogo, o corte seletivo, a fragmentação florestal [3], micro-explosões ocasionadas por correntes de ventos descendentes, quedas de raios, alta pressão por caça, além da ação combinada entre as diferentes fontes de degradação e destas com as mudanças climáticas em curso [1]. Estes fenômenos podem produzir, mais rápido ou mais lento, efeitos danosos na sustentabilidade florestal dependendo da sua intensidade e mecanismo de ação, e isto se reflete na complexidade do seu monitoramento e detecção.

Enquanto alguns distúrbios já tem metodologias consolidadas, como a detecção de desmatamento, outros distúrbios mais complexos ainda estão em constante evolução e melhoria das técnicas de detecção. Uma forma generalista de reconhecimento destes padrões é o uso de técnicas de identificação de mudanças na estrutura da vegetação como um todo. Assim, a utilização de séries temporais é fundamental para se obter o comportamento histórico da vegetação e assim verificar a existência de distúrbios.

O algoritmo *Breaks For Additive Season and Trend Monitor - BFAST* permite a detecção de mudanças em séries temporais por meio da utilização de modelos com base nos desagregação da série temporal em seus componentes de sazonalidade e tendência [4]. Sendo amplamente utilizado no estudo de distúrbio florestais em diferentes fitofisionomias [5–7].

O estado do Maranhão está localizado em uma região de transição fitogeográficas (Amazônia e Cerrado). Esta localização torna o estado sujeito a diferentes níveis de políticas de preservação e a diferentes níveis de

enfrentamento. Apenas no ano de 2020 o estado se encontra, em terceiro colocado em relação os estados que mais desmata no Brasil, com aproximadamente 1.638 km² [8], e em quarto lugar nos estados com as maiores áreas queimadas registradas no ano, com aproximadamente 13.720 km² [9].

O objetivo deste artigo foi avaliar o uso do método BFAST monitor aplicado aos cubos de dados de imagens Landsat para identificar áreas florestais com algum distúrbio através do monitoramento da série temporal pixel a pixel de NDVI ao longo dos últimos 4 anos.

2. MATERIAL E MÉTODOS

A área de estudo selecionada, foi o estado do Maranhão localizado no nordeste brasileiro, Figura 1. O Estado está inserido no ecótono de transição entre os biomas Amazônia e Cerrado [10], sendo considerado um local prioritário de conservação.




Figura 1: Localização da área de estudo, com destaque para os tiles do BDC.

Para delimitação das florestas primárias do Maranhão, foi utilizado os dados de localização de florestas primárias disponibilizado pelo projeto MapBiomas por meio da sua coleção 6 de áreas desmatadas [11] agregados aos dados de uso e cobertura da coleção 7, selecionando as classes Floresta e Savana de 2020 [12, 13].

Foi utilizado o índice de vegetação de diferença normalizada (NDVI) do cubo de dados Landsat de 16 dias (LC8_30_16D_STK) entre os anos de 2016 e 2020, disponibilizados pelo projeto *Brazil Data Cube - BDC*. Ao total foram utilizados 13 tiles que recobrem toda a extensão do estado do Maranhão (Figura 1).

Os cubos de dados LC8_30_16D_STK produzido pelo projeto BDC são originados a partir de imagens de reflectância de superfície do sensor OLI com resolução espacial de 30 metros, sendo um composto temporal de 16 dias, ou seja utiliza o pixel sem nuvem mais recente dentro

desta janela temporal, agregado e distribuído em células de 2x3 graus denominadas *tiles* [14, 15].

Os dados inicialmente foram filtrados pela quantidade de Nuvens, removendo, assim, pixel cuja série continha mais de 60% (55 registros) de nuvens. Para tanto utilizou a banda FMASK do conjunto de dados do cubo LC8_30_16D_STK. Os pixels restantes, foram submetidos a um preenchimento linear dos valores faltantes utilizando a função `na.interp` da biblioteca `forecast` [16, 17].

Por fim utilizou-se a função `bfastmonitor` [4] da biblioteca `bfast` [18, 19] para se estimar distúrbios ocorrido na vegetação no ano de 2020 com base no comportamento reconhecido entre os anos de 2016 e 2019. A função foi configurada para retornar os pixels que apresentaram alguma quebra de tendência significativa na sua trajetória, bem como a sua magnitude e direção.

Para se correlacionar com os possíveis distúrbios encontrados na região, utilizou-se o produto de áreas queimadas da coleção 1 do MapBiomas [9], e o de desmatamento da coleção 6 do MapBiomas [11] atualizado para 2020 com o mapeamento de uso e cobertura da coleção 7 [13].

3. RESULTADOS

Do total de 177.060 km² de vegetação primárias remanescentes em 2020, 49.988 km² foram excluídos pois representam áreas com mais de 60% de cobertura de nuvem entre o período de 2016 a 2020. Desta forma foram analisados 127.072 km² de vegetação nativa no estado do Maranhão (Figura 2a).

Desta área foi observado que cerca de 49% (62.207 km²) apresentou alguma tendência, seja de crescimento (~50.738 km²) ou de declínio (~11.469 km²) durante todo o período analisado. Das áreas cujo tendência foi de crescimento, 36% (~18.217 km²) apresentaram uma quebra na sua tendência devido à algum distúrbio para o ano de 2020. Considerando as áreas de declínio, aproximadamente 46% (~5.309 km²) apresentaram uma quebra para o ano de 2020.

Comparando separadamente com as áreas queimadas e as áreas desmatadas mapeadas pelo MapBiomas (Tabela 1), e realizando a matriz de erros para ambos (Tabela 2), temos que o BFAST tem uma acurácia global de 73% considerando as áreas queimadas e de 71% considerando as áreas desmatadas. Porém, a acurácia do Usuário para ambas os distúrbios no que se diz respeito à identificação de uma quebra é de 11% para áreas queimadas e de 1% para áreas desmatadas.

Quebra	Tendência	Queimada		Desmatamento	
		Não	Sim	Não	Sim
Não	Negativa	5,984.21	175.68	6,002.15	157.74
	Sem	50,426.11	1,443.44	51,471.70	397.84
	Positiva	32,107.41	413.83	32,392.23	129.01
Sim	Negativa	5,071.09	238.36	5,206.77	102.68
	Sem	11,438.26	1,556.84	12,852.02	143.07
	Positiva	16,135.72	2,081.14	18,115.88	100.97

Tabela 1: Área total em km² identificada pelo BFAST como quebra ou não e sua respectiva tendência em relação às áreas mapeadas de desmatamento e queimadas pelo MapBiomas.




Figura 2: Mapa da cobertura de nuvem para a região (a); distribuição espacial das tendências encontradas (b); tendências que apresentaram alguma quebra para o ano de 2020 (c); e a distribuição das áreas queimadas [9] e das áreas desmatadas [8, 13] segundo o produto do MapBiomas. Todos os mapas estão filtrados para a região de remanescente florestal, e para os mapas de b a d adicionou ainda a restrição da cobertura de nuvens menores que 60%.

Distúrbio	Quebra	Acurácia		
		Usuário	Produtor	Global
Queimada	Não	98%	73%	73%
	Sim	11%	66%	
Desmatamento	Não	99%	71%	71%
	Sim	1%	34%	

Tabela 2: Acurácia global, do usuário e do produtor considerando separadamente área queimada e desmatamento para a região.

4. DISCUSSÃO

Da área total de vegetação primária remanescente no estado do Maranhão 28% foram excluídas da análise pois estão com altas taxas de cobertura de nuvens, representando, assim, grandes ruídos para a avaliação. Estas faixas se encontram principalmente na região Norte e Noroeste do Estado (Figura 2a), zonas de domínio do bioma Amazônia. Região esta que sofre com o baixo número de observações válidas durante o ano, alcançando na média uma imagem válida por mês apenas entre os meses de Junho a Setembro [20].

Mesmo assim, algumas faixas com valores menores de cobertura de nuvens foram observadas dentro da região. Porém, este efeito se deve ao fato do cubo de dados LC8_30_16D_STK disponibilizado pelo BDC, utilizar uma grade (tile) própria [14, 15], incluindo, assim, as zonas de sobreposição existente entre as imagens do sensor OLI do Landsat-8.

A detecção de distúrbios no Cerrado é desafiadora uma vez que a variação fenológica da vegetação e o aparecimento de solo exposto pode se gerar confusão com áreas desmatadas ou queimadas [21]. Entretanto neste estudo temos uma baixa taxa de super-identificação de distúrbios, indicado pela maior acurácia do usuário e do produtor para a classe sem quebras (Tabela 2).

Por outro lado, esse baixa identificação de quebras levou à uma sub-notificação de locais com distúrbios, o que fica nítido ao se analisar o erro de comissão (Tabela 2)

para locais com quebras. Diferente do apontado por Yuan et al. (2020) [22], onde os autores demonstram que o BFASTmonitor exibe grande sensibilidade à variações no comportamento de índices espectrais comparado à outros métodos, levando a uma super-notificação de distúrbios.

Sob uma outra ótica, observamos que mesmo indivíduos que não estão sofrendo algum estresse, ou seja, aqueles locais sem tendência ou com tendência positiva no comportamento do NDVI, apresentaram algum distúrbio mapeado. Estas áreas representam cerca de 6.227 km² ou aproximadamente 5% do total mapeado. Em relação as áreas com tendência negativa, do total de 11.469 km² mapeados, aproximadamente 667 km² (6%) tiveram um distúrbio mapeado.

Proporcionalmente as florestas vulneráveis continuam sofrendo com a entrada de algum distúrbio, porém não são exclusivas uma vez que a parcela de florestas saudáveis estão tendo o mesmo destino. Delineando mais uma vez, que distúrbios antrópicos, como o caso de queimadas e desmatamento, podem acometer todo o tipo de vegetação não só as vulneráveis climaticamente.

5. CONCLUSÕES

Determinar distúrbios florestais é desafiador, principalmente se tratando de uma região de transição entre fitofisionomias. A utilização do BFAST monitor para se identificar quebras na série temporal de NDVI para 2020 tendo como base os dados de 2016 a 2019 mostrou uma acurácia global de 73%, porém com um erro de comissão de 99% no que se diz respeito à eventos de desmatamento. Mesmo assim os padrões observados para região indicaram que nem toda formação florestal nativa que sofre um distúrbio está sob algum processo de estresse, o que se refletiria no declínio do índice NDVI de vegetação e aumento da sua vulnerabilidade aos processos de degradação. Além disso o método indica zonas com diferentes tendências, enriquecendo a análise de vulnerabilidade para regiões.

Agradecimentos

Ao subprojeto Brazil Data Cube, do Projeto Monitoramento Ambiental dos Biomas Brasileiros, financiado com recursos do Fundo Amazônia, por meio da colaboração financeira BNDES e FUNCATE nº 17.2.0536.1. Ao INPE pela infraestrutura de processamento e análise. Ao projeto MAP-Fire Maranhão, financiado pela FAPESP (process nº 2020/16457-3), FAPEMA (process nº 02989/20) em parceria com o "Climate Science for Service Partnership Brazil (CSSP Brazil)". A Universidade de Manchester pelo apoio a CHLSJ por meio do projeto "Forest fragmentation mapping of Amazon and its vulnerable margin Amazon-Cerrado transition forests", realizado, em parte, no Jet Propulsion Laboratory sob contrato com a NASA.

6. REFERÊNCIAS

- [1] Joice Ferreira, Lilian Blanc, Milton Kanashiro, Alexander Charles Lees, Clément Bourgoïn, Joberto Veloso Freitas, Michelliny Bentes Gama, François Laurent, Marlucia Bonifácio Martins, Nárgila Moura, Marcus Vinicius d'Oliveira, Eleneide Doff Sotta, Cintia Rodrigues Souza, Ademir R. Rushchel, Gustavo Schwartz, Joeri Zwerts, and Plinio Sist. Degradação florestal na Amazônia: como ultrapassar os limites conceituais, científicos e técnicos para mudar esse cenário. Technical Report 413, Embrapa Amazônia Oriental, Belém - PA, 2015. ISSN 1983-0513.
- [2] David B. Clark. The role of disturbance in the regeneration of neotropical moist forests. In K.S. Bawa and M. Hadley, editors, *Reproductive ecology of tropical forest plants*, volume 7 of *Man and the biosphere series*. 1990.
- [3] R Beuchle, F Achard, C Bourgoïn, C Vancutsem, HD Eva, and M Follador. Desflorestação e degradação florestal na amazônia. 2022.
- [4] Jan Verbesselt, Achim Zeileis, and Martin Herold. Near real-time disturbance detection using satellite image time series. *Remote Sensing of Environment*, 123:98–108, 2012.
- [5] Inacio T. Bueno, Greg J. McDermid, Eduarda M. O. Silveira, Jennifer N. Hird, Breno I. Domingos, and Fausto W. Acerbi Júnior. Spatial agreement among vegetation disturbance maps in tropical domains using landsat time series. *Remote Sensing*, 12(18), 2020.
- [6] Yan Gao, Jonathan V. Solórzano, Alexander Quevedo, and Jaime Octavio Loya-Carrillo. How BFAST Trend and Seasonal Model Components Affect Disturbance Detection in Tropical Dry Forest and Temperate Forest. *Remote Sensing*, 13(11):2033, May 2021.
- [7] Jonathan V. Solórzano and Yan Gao. Forest Disturbance Detection with Seasonal and Trend Model Components and Machine Learning Algorithms. *Remote Sensing*, 14(3):803, February 2022.
- [8] MapBiomass. Relatório Anual de Desmatamento 2021. Technical report, São Paulo - SP, 2022.
- [9] MapBiomass. "projeto mapbiomas – mapeamento de cicatrizes de fogo no brasil coleção 1, 2022.
- [10] Instituto Brasileiro de Geografia e Estatística, editor. *Biomass e sistema costeiro-marinho do Brasil: compatível com a escala 1:250 000*. Number volume 45 in Série Relatórios metodológicos. IBGE, Rio de Janeiro, 2019.
- [11] MapBiomass. Projeto MapBiomass - coleção 6 da série anual de mapas de desmatamento e regeneração do brasil, 2022.
- [12] Carlos M. Souza, Julia Z. Shimbo, Marcos R. Rosa, Leandro L. Parente, Ane A. Alencar, Bernardo F. T. Rudorff, Heinrich Hasenack, Marcelo Matsumoto, Laerte G. Ferreira, Pedro W. M. Souza-Filho, Sergio W. de Oliveira, Washington F. Rocha, Antônio V. Fonseca, Camila B. Marques, Cesar G. Diniz, Diego Costa, Dyeden Monteiro, Eduardo R. Rosa, Eduardo Vélez-Martin, Eliseu J. Weber, Felipe E. B. Lenti, Fernando F. Paternost, Frans G. C. Pareyn, João V. Siqueira, José L. Viera, Luiz C. Ferreira Neto, Marciano M. Saraiva, Marcio H. Sales, Moises P. G. Salgado, Rodrigo Vasconcelos, Soltan Galano, Vinicius V. Mesquita, and Tasso Azevedo. Reconstructing three decades of land use and land cover changes in brazilian biomes with landsat archive and earth engine. *Remote Sensing*, 12(17), 2020.
- [13] MapBiomass. Projeto MapBiomass - coleção 7 da série anual de mapas de cobertura e uso da terra do brasil, 2022.
- [14] BDC. Lc8_30_16d_stk description, 2022.
- [15] Karine R. Ferreira, Gilberto R. Queiroz, Lubia Vinhas, Rennan F. B. Marujo, Rolf E. O. Simoes, Michelle C. A. Picoli, Gilberto Camara, Ricardo Cartaxo, Vitor C. F. Gomes, Lorena A. Santos, Alber H. Sanchez, Jeferson S. Arcanjo, José Guilherme Fronza, Carlos Alberto Noronha, Raphael W. Costa, Matheus C. Zaglia, Fabiana Zioti, Thales S. Korting, Anderson R. Soares, Michel E. D. Chaves, and Leila M. G. Fonseca. Earth observation data cubes for brazil: Requirements, methodology and products. *Remote Sensing*, 12(24), 2020.
- [16] Rob J Hyndman and Yeasmin Khandakar. Automatic time series forecasting: the forecast package for R. *Journal of Statistical Software*, 26(3):1–22, 2008.
- [17] Rob Hyndman, George Athanasopoulos, Christoph Bergmeir, Gabriel Caceres, Leanne Chhay, Mitchell O'Hara-Wild, Fotios Petropoulos, Slava Razbash, Earo Wang, and Farah Yasmeen. *forecast: Forecasting functions for time series and linear models*, 2022. R package version 8.17.0.
- [18] Jan Verbesselt, Rob Hyndman, Glenn Newnham, and Darius Culvenor. Detecting trend and seasonal changes in satellite image time series. *Remote Sensing of Environment*, 114(1):106–115, 2010.
- [19] Jan Verbesselt, Rob Hyndman, Achim Zeileis, and Darius Culvenor. Phenological change detection while accounting for abrupt and gradual trends in satellite image time series. *Remote Sensing of Environment*, 114(12):2970–2980, 2010.
- [20] Jean Francois Mas, Carlos Henrique Sopchaki, Francisco Davy Braz Rabelo, Francisca Soares de Araújo, and Jonathan Vidal Solórzano. Análise da disponibilidade de imagens Landsat e Sentinel para o Brasil. *Geografia Ensino & Pesquisa*, 24:e47, December 2020.
- [21] Alana Almeida de Souza, Lênio Soares Galvão, Thales Sehn Korting, and Cláudio Aparecido Almeida. On a Data-Driven Approach for Detecting Disturbance in the Brazilian Savannas Using Time Series of Vegetation Indices. *Remote Sensing*, 13(24):4959, 2021.
- [22] Yuan Yuan, Lei Lin, Lian-Zhi Huo, Yun-Long Kong, Zeng-Guang Zhou, Bin Wu, and Yan Jia. Using an attention-based lstm encoder-decoder network for near real-time disturbance detection. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 13:1819–1832, 2020.